RUCODE festival

Айайай 360

PRO: Анти-фейк (МТС)

Щеглов Сергей Денисович, МФТИ, г. Долгопрудный
Тымчишин Кирилл Витальевич, МФТИ, г. Долгопрудный
Окулов Никита Владимирович, МФТИ, г. Долгопрудный

На пути к решению

RUCODE festival

1. Основная идея: Представление звука картинкой

От признаков исходной волны и классических моделей перешли к CNN на log-power спектрограммах.

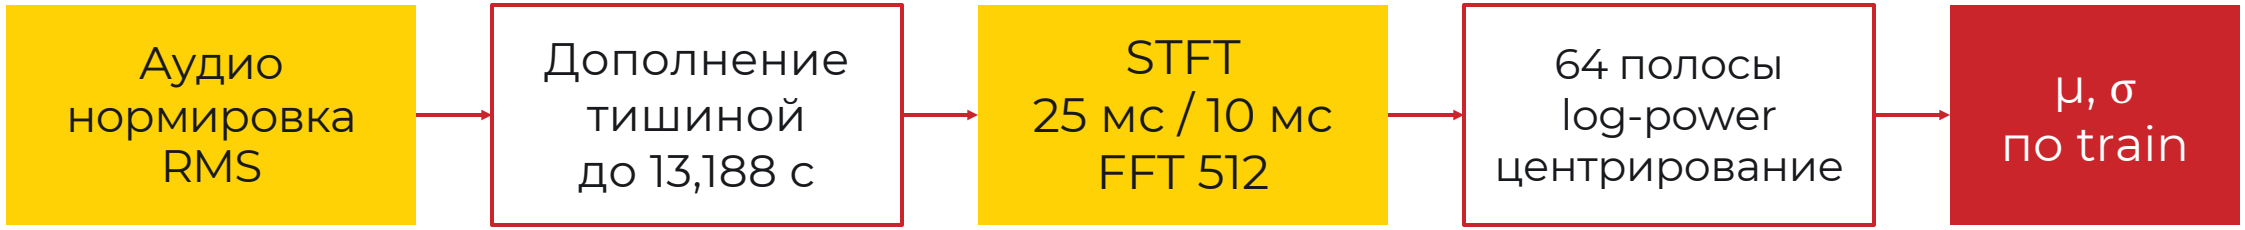
2. Основной принцип: Распределение задач

Чтобы не делать одну и ту же подзадачу дважды. Это помогло нам проверить много различных гипотез



Решение: предобработка аудио

Исходные записи: моно, 16 кГц. В CNN поступает тензор

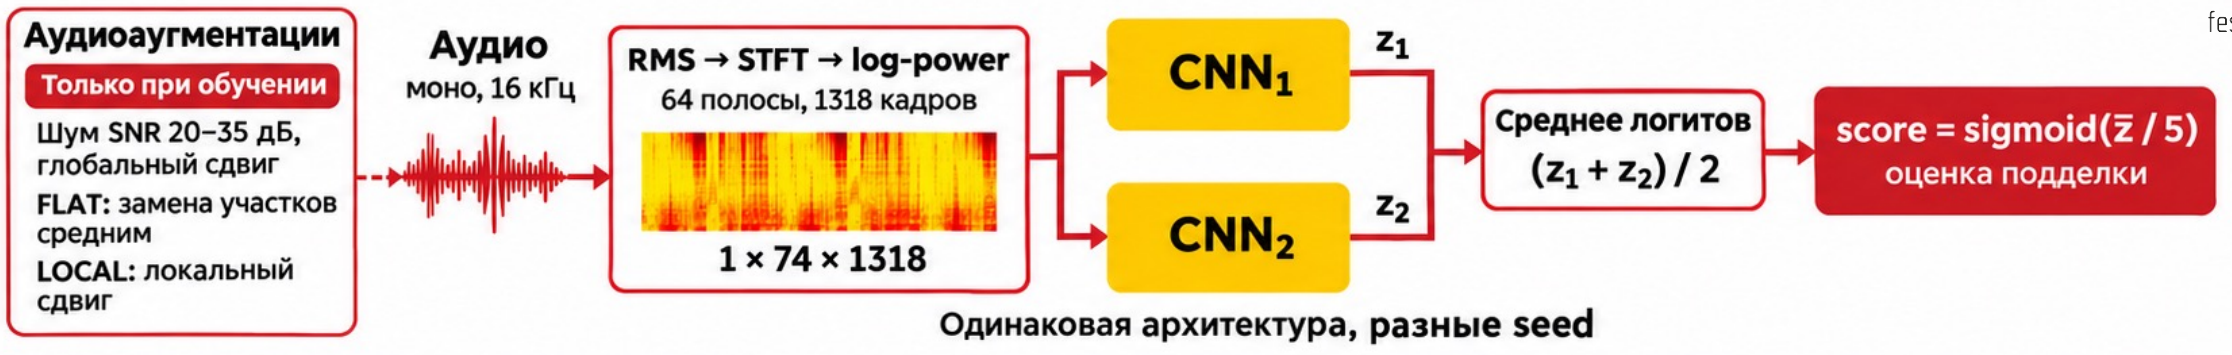


64 частотные полосы × 1318 временных кадров

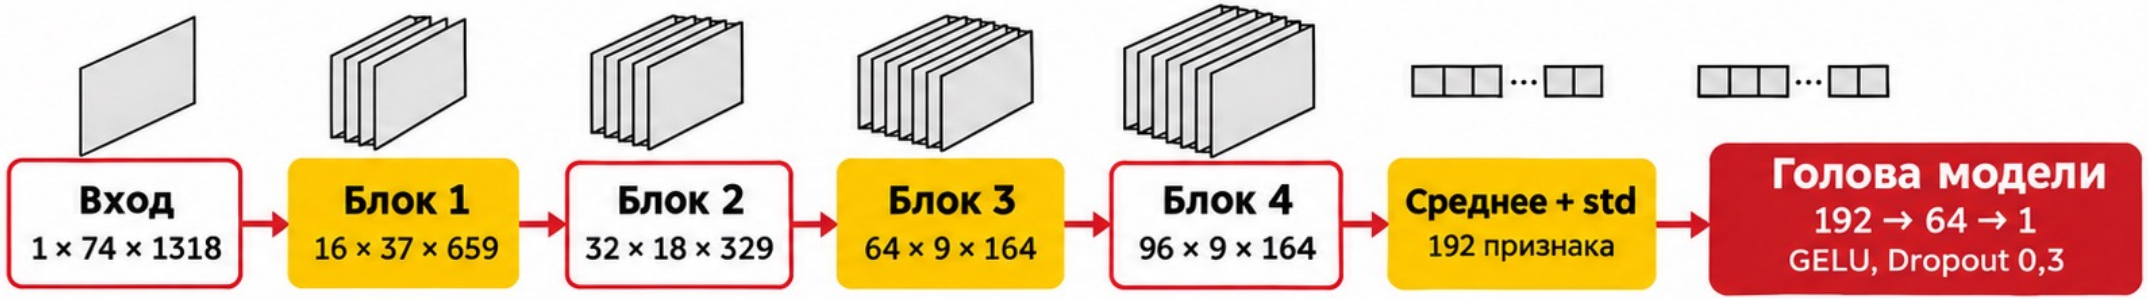
Сохраняем полную временную сетку. Статистики стандартизации считаем только на обучающей части каждого разбиения.

Технический вход CNN: 1 × 74 × 1318. К 64 полосам добавлены 10 нулевых строк.

Итоговая архитектура



Одна CNN — 91 521 параметр



Блоки: Conv 3×3 + BatchNorm + GELU. После блоков 1–3: AvgPool 2×2.

183 042 параметров
суммарно у двух CNN

Обучение: 4 эпохи, batch 8, AdamW: lr = 0,001, weight decay = 0,01
За эпоху: 3000 настоящих + 3000 синтетических примеров, с возвращением
Шум признаков σ = 0,03, маскирование 8 временных кадров
По логам: 65,52 с и 63,20 с на сети соответственно, без построения кэша

Public: 100,00 (ROC-AUC × 100, округлено)

Проверили, но не включили в финал

Спектральные перепады как признаки синтеза

Гипотеза: резкие перепады выдают синтез. Классификатор использовал максимальный перепад.

ROC-AUC по генераторам
A04: 0,934
A05: 0,389

Восстановление скрытых признаков

Трансформер восстанавливает пропуски. Статистики ошибок подаём классификатору.

Public 92,14

Обучаемые границы фрагментов

Сеть сама выбирает три участка записи. На трудном разбиении уступила фиксированным границам.

Public 98,59
Local 0,882 / 0,982[1]

Каталог проверенных гипотез и результатов на Google Drive

Public: ROC-AUC × 100. Local: ROC-AUC. A04/A05 — разные генераторы.
[1] Score с реализованной идеей / без реализованной идеи. Local для границ: G3/A03.

Сложности, которые преодолели

RUCODE festival

1. Как генерировать новые признаки

Проверяли спектральные перепады, фазу и ошибки восстановления скрытых признаков.

2. Сделать аккуратную валидацию

OOD (out of distribution): проверка на новых дикторах и неизвестном генераторе. Исключали их из обучения.



3. Выбор финальной модели

Сравнивали score на public, локальную устойчивость и размер модели.

Команда



Тымчишин Кирилл, МФТИ, AI360

Основной вклад в решение задачи C, Небольшое участие в решении задачи D



Щеглов Сергей, МФТИ, AI360

Координация и участие в решении задач C и D



Окулов Никита, МФТИ, AI360

Основной вклад в решение задачи D, Небольшое участие в решении задачи C

RUCODE FESTIVAL

ЖДЕМ ВАС!



Материалы для вопросов: слайд 9

Материалы для вопросов: навигация

10. Данные и валидация

11. Выбор финальной модели

12. Точная обработка аудио

13. Архитектура и параметры

14. Обучение и время

15. Базовые аугментации

16. FLAT и LOCAL

17. Метрики и итоговые результаты

18. Восстановление скрытых признаков

19. Обучаемые границы фрагментов

20. Обращение градиента по диктору

21. Трудные случаи и ограничения

22. Воспроизводимость и источники

Данные и схема валидации

Набор	Записей	Разметка
Train	25 380	2580 настоящих, 22 800 синтетических
Public	1162	Официальные метки недоступны
Private	2712	Официальные метки недоступны

Разбиение: новые дикторы и неизвестный генератор

Одну из пяти акустических групп дикторов и один генератор целиком исключаем из train. Нормировку рассчитываем только по train.

Разбиение	Train / validation	Основная оценка
G3/A03	11 957 / 11 317	Исключённый генератор против настоящей речи
G5/A05	18 409 / 3729	Те же условия на другой группе
G1/A06	17 242 / 5102	Те же условия на другой группе

К навигации

Выбор финальной модели

Вариант	Public	Local mean	Local worst
GAIN + FLAT	99,88	0,962024	0,930554
GAIN + LOCAL	99,99	0,901359	0,791897
FL_REPEAT	100,00	0,905945	0,726018
GAIN + FLAT + LOCAL	99,91	0,943919	0,901077

Финальная отправка: лучший отображаемый public-балл

Локальная проверка характеризует перенос на новые дикторы и генераторы. Она не стала обязательным критерием финального выбора. Лучшее качество на private из этих чисел не следует.

Public использован для выбора модели, поэтому не является независимой итоговой оценкой. Малые различия округлённого балла не доказывают превосходство.

К навигации

Точная обработка аудио

Шаг	Параметры и порядок
Исходная волна	Mono 16 кГц. Обрезка по train-максимуму 211 007 отсчётов
Амплитуда	$x / (\mathrm{RMS}(x) + 10^{-9})$, RMS до длинного дополнения тишиной
Дополнение	Нули до 211 007 отсчётов до вычисления спектра
STFT	Hann 400, overlap 240, hop 160, FFT 512, boundary=None, padded=True
Мощность и полосы	$\lvert\mathrm{STFT}\rvert^2 + 10^{-10}$. Бины 1…256 усредняются по 4 в 64 полосы
Log-power	Натуральный логарифм с ε, затем вычитание среднего карты записи
Стандартизация	$(L - \mu\mathrm{train}) / \sigma\mathrm{train}$ по частотам. Ограничение значений [−12, 12]
Вход сети	1318 кадров. 64 полосы и 10 нулевых строк: B × 1 × 74 × 1318

Нули в звуковой волне и нули в карте признаков дают разную обработку. Готовые веса требуют сохранения исходного порядка.

К навигации

Архитектура: размеры и параметры

Слой	Выход без B	Параметров
Вход	1 × 74 × 1318	0
Conv 1→16, BN, GELU, AvgPool	16 × 37 × 659	192
Conv 16→32, BN, GELU, AvgPool	32 × 18 × 329	4704
Conv 32→64, BN, GELU, AvgPool	64 × 9 × 164	18 624
Conv 64→96, BN, GELU	96 × 9 × 164	55 584
Глобальные mean + std	192	0
Linear 192→64, GELU, Dropout 0,3	64	12 352
Linear 64→1	1 логит	65
Итого на сеть / две сети	Одинаковая архитектура	91 521 / 183 042

Все свёртки 3 × 3, stride 1, padding 1. Пулинг 2 × 2 после первых трёх блоков. В число параметров не входят служебные running-статистики BatchNorm.

К навигации

Обучение и измеренное время

Параметр	Значение
Библиотека и старт	PyTorch, обучение с нуля, внешних предобученных весов нет
Оптимизатор	AdamW, lr 0,001, weight decay 0,01
План скорости	Косинусный, горизонт 14 эпох, выполнены первые 4 эпохи
Функция потерь	Бинарная кросс-энтропия по логитам
Выборка	3000 настоящих + 3000 синтетических за эпоху, с возвращением
Размер батча и шаги	8 примеров, 750 обновлений за эпоху, 3000 на сеть
Ограничение градиента	Норма не более 5
Два seed	639320754 и 639320755
Время эпох, сумма	65,52 с и 63,20 с. Вместе 128,72 с, без построения кэшей

Оборудование исходного обучения в метаданных не сохранено. Это время конкретных запусков, а не обещание скорости на любом компьютере.

К навигации

Базовые аугментации

Преобразование	Как применяется
Шум исходной волны	Гауссов шум, SNR 20–35 дБ. Длина сохраняется
Частота шума по классам	P(шум | настоящая) = 0,75, P(шум | синтетика) = 0,5
Глобальный сдвиг	С вероятностью 0,5. Сдвиг кратен 160 отсчётам внутри тишины
Шум карты признаков	Гауссов шум с $\sigma = 0{,}03$ после стандартизации
Маскирование времени	С вероятностью 0,5 за батч зануляем общие 8 кадров
Сохранение метки	Преобразованная настоящая речь остаётся настоящей
Предсказание	Аугментации отключены

Вероятность 0,75 получается объединением двух независимых событий по 0,5: $1 - (1 - 0{,}5)^2$. Шум добавляется один раз.

К навигации

FLAT и LOCAL: точные преобразования

FLAT: замена коротких участков средним

Выбираем 1–3 участка по 5–20 мс, каждый не длиннее 1% записи. Заменяем значения участка его средним. На краях плавное смешивание около 1 мс.

LOCAL: небольшой сдвиг внутри участка

Выбираем участок 40–120 мс, не длиннее 10% записи. Сдвигаем содержимое на ±2–10 мс. Освободившиеся отсчёты заполняем нулями, края сглаживаем около 2 мс.

Совместный вариант FLAT + LOCAL выбирается с вероятностью 0,5. Затем RMS-нормировка. Базовые шум и глобальный сдвиг сохраняются.

Общая длина сохраняется. LOCAL может терять часть отсчётов внутри участка. Один закэшированный альтернативный вариант на файл.

К навигации

Метрики и итоговые результаты

Где измеряли	Результат FL_REPEAT	Что означает
Train	BCE 0,419861 / 0,372114	Последняя эпоха двух сетей, с аугментациями
Локально G3/A03	ROC-AUC 0,996932	Новые дикторы, исключённый генератор
Локально G5/A05	ROC-AUC 0,726018	Наиболее трудное из трёх разбиений
Локально G1/A06	ROC-AUC 0,994886	Те же условия на другой группе
Public	100,00 балла	Округлённый ROC-AUC × 100
Private	100 баллов	На яндекс.контест

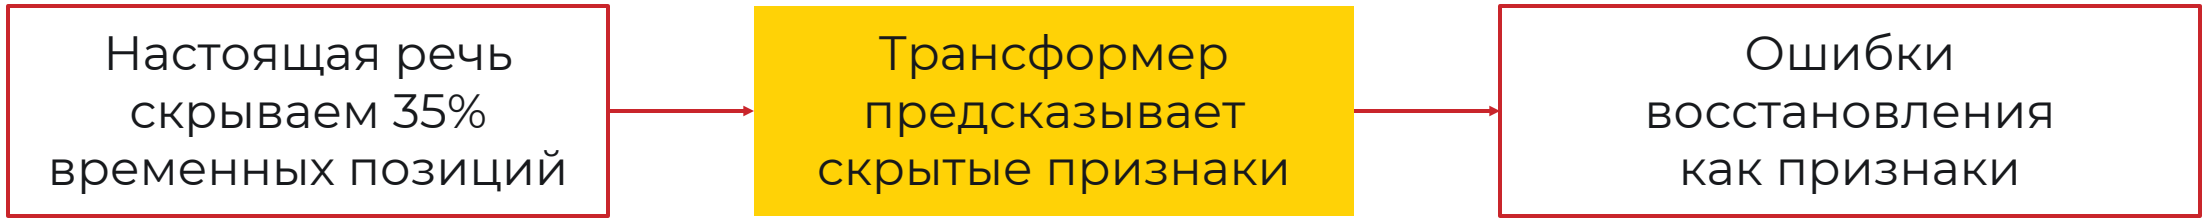
score = sigmoid($(z_1 + z_2) / 10$)

ROC-AUC оценивает порядок настоящих и синтетических записей. Он не равен accuracy. Шкала /5 сохраняет порядок логитов, но не калибрует вероятности.

К навигации

Восстановление скрытых признаков

Гипотеза: синтез меняет закономерности, по которым соседние участки речи предсказывают друг друга



Обучение восстановителя: только настоящая речь. Два слоя трансформера, размерность 64, четыре головы внимания. Ошибка: MSE + 0,2 × косинусная ошибка.

Public 92,14. Восстанавливаем акустические признаки, а не звуковую волну. Большая ошибка не обязана означать подделку.

К навигации

Обучаемые границы фрагментов

Модель сама выбирает три информативных фрагмента вместо заранее фиксированных положений

Временная CNN предсказывает три начала интервалов. Длина каждого — 100 кадров STFT, около 1 секунды. Дифференцируемое извлечение позволяет обучать границы по метке целой записи. Логиты трёх фрагментов усредняются.

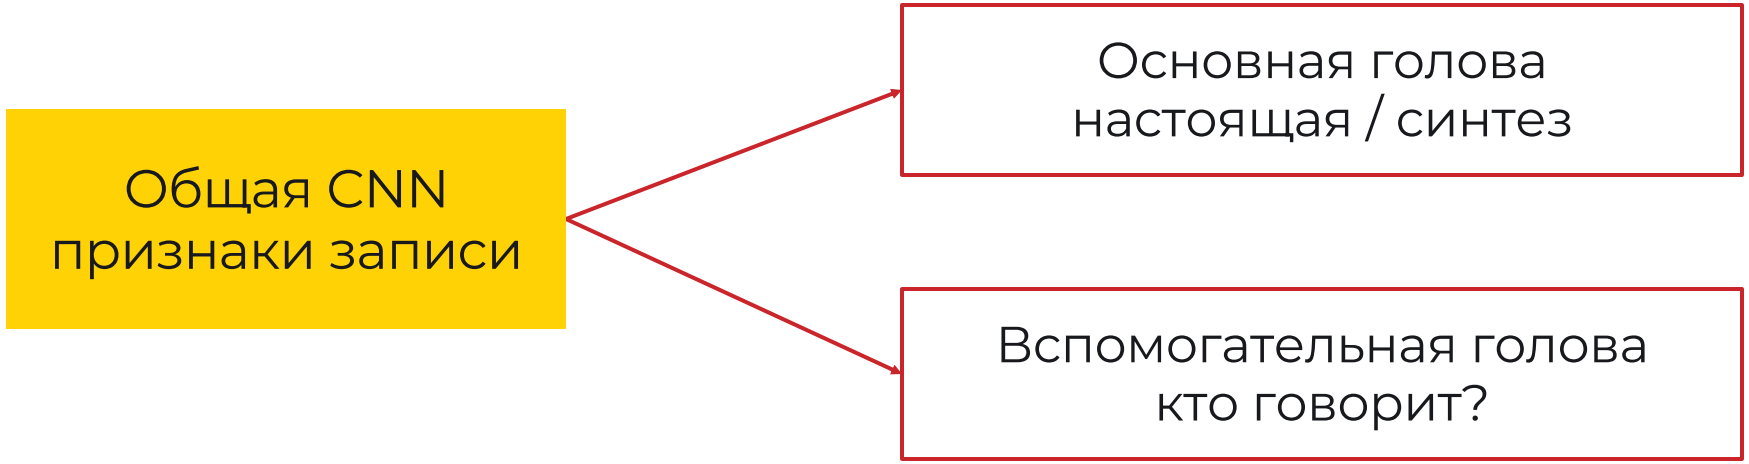
Разбиение	Фиксированные границы	Обучаемые границы
G3/A03	0,982114	0,881839
G5/A05	0,999722	0,999958
G1/A06	0,993726	0,979288

Public 98,59. Отдельного официального public-контроля нет. На трудном локальном разбиении обучаемые границы уступили фиксированным.

К навигации

Обращение градиента по диктору

Одна общая сеть, две головы: подделка и личность диктора



Градиент к общей сети: $\nabla\theta$ L(подделка) − 0,1 $\nabla\theta$ L(диктор)

Голова диктора учится распознавать голос. Общая CNN получает противоположный сигнал от этой задачи и сохраняет признаки, полезные для определения подделки.

К навигации

Трудные случаи и ограничения

Новый генератор на новой группе голосов

G5/A05: ROC-AUC 0,726018 против 0,996932 и 0,994886 на двух других трудных разбиениях. Обобщение зависит от конкретного сочетания условий.

Разные случайные инициализации

На G5/A05 разница AUC отдельных seed составила 0,174. Двух запусков недостаточно для точной оценки дисперсии обучения.

Граница известных результатов

Для private нет истинных меток. Нет подтверждённой разметки локальных артефактов. Нельзя обещать перенос на любые генераторы, кодеки и шумы.

К навигации

Воспроизводимость и источники

Финальный рецепт: FL_REPEAT / BEST100. Две сети, сохранённый нормировщик, фиксированная обработка входа

Обучение: python train.py --train /path/to/train --device auto

Предсказание: python predict.py --input /path/to/audio
--sample /path/to/sample.csv --output results.npz --device auto

Проверка пакета: python verify.py. Сохранены 2712 private-ответов. Включённый public-файл содержит 1162 ответа.

Финальный пакет на Google Drive

README, каталог исследований и исходный код. Каталог содержит 184 записи, включая контроли и повторы, а не 184 независимые гипотезы.

К навигации